SISTEMAS AVANZADOS DE PRODUCCION – 9CN

TALLER 1: ANÁLISIS PREDICTIVO Y APRENDIZAJE ESTADÍSTICO

CASO DE ESTUDIO: ADVERTISING DATA

DOCENTE: FREDY ALEXANDER ORJUELA LOPEZ

KAROL LORENA MANIOS TALERO– 122675

KAREN TATIANA CAÑON ESPINOSA - 112050

MARÍA ALEJANDRA BOCAREJO HERNÁNDEZ – 124099

UNIVERSIDAD ECCI

FACULTA DE INGENIERIA

PROGRAMA DE INGENIERIA INDUSTRIAL

BOGOTÁ D.C.

1 DE MARZO DEL 2026

Tabla de contenido

Introducción 3

FASE 1: Estadística descriptiva y análisis exploratorio 4

1. (2) Caracterización numérica 4

2. Análisis de Distribución y Atípicos: 4

3. Exploración de la Nube de Puntos: 6

5. Interpretación de Resultados: (Matriz de correlación de Pearson y Spearman): .. 9

FASE 2: Regresión Lineal y Diagnóstico 11

1. Modelamiento Múltiple: 11

2. Interpretación de Parámetros: 11

3. Análisis de Bondad de Ajuste: 12

4. Estimación Matricial: 12

FASE 3: Arboles de Decisión y Comparación de Modelos 14

1. Entrenamiento del Modelo: 14

2. Cálculo Manual de Incertidumbre (Clasificación): 14

3. Importancia de Predictores: 16

4. Diagnóstico Comparativo: 16

Conclusiones: 17

Introducción

El presente análisis aborda el impacto de la inversión publicitaria en las ventas a través del conjunto de datos, el cual registra el comportamiento de mercados frente a la inversión en TV, radio y periódico, el objetivo principal es determinar la eficiencia de cada canal de comunicación y cuantificar su relación con el volumen de ventas mediante técnicas de aprendizaje estadístico.

Para lograrlo, el estudio se estructura en tres fases: primero, una caracterización descriptiva y exploratoria para identificar patrones y correlaciones; segundo, el desarrollo de un modelo de regresión lineal múltiple (mediante software y estimación matricial) para medir el impacto marginal de cada medio; y finalmente, la implementación de un árbol de decisión para capturar interacciones no lineales. El análisis busca proporcionar una base técnica sólida que permita optimizar la asignación de presupuestos publicitarios basada en la capacidad predictiva de los modelos evaluados.

FASE 1: Estadística descriptiva y análisis exploratorio

1. (2) Caracterización numérica

Medidas de tendencia central y dispersión

Variable	Mean	Median	Std	Min	Max	Skewness	Kurtosis
TV	147.0425	49.75	85.854236	0.7	296.4	-0.069853	-1.226495
Radio	23.2640	2.90	14.846809	0.0	49.6	0.094175	-1.260401
Newspaper	30.5540	25.75	21.778621	0.3	114.0	0.894720	0.649502
Sales	14.0225	12.90	5.217457	1.6	27.0	0.407571	-0.408869

Tabla 1 / Caracterización numérica

Tabla (1): Esta tabla nuestra las medidas de tendencia central y de dispersión para las variables independientes y para la variable Sales dependiente.

2. Análisis de Distribución y Atípicos:

Construcción de cada histograma para cada variable:

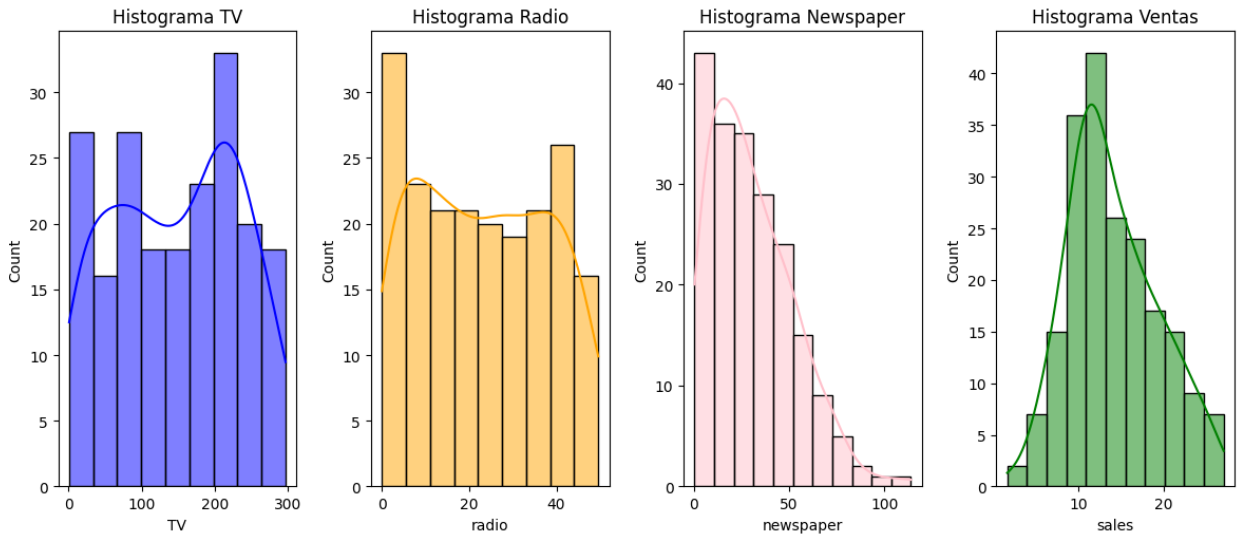

Ilustración 1 / Histograma de cada variable (TV, Radio, Newspaper, Sales)

Construcción de cada boxplot para cada variable:

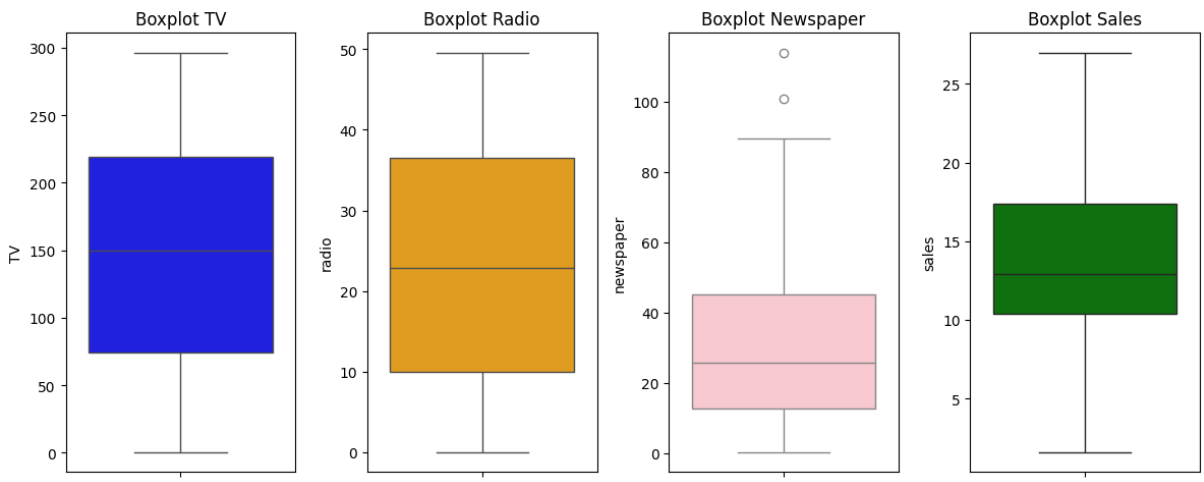

Ilustración 2 / Boxplot de cada variable (TV, Radio, Newspaper, Sales)

Determine la simetría de las distribuciones:

Tv: Esta distribución es prácticamente casi simétrica, esto al ser un valor tan cercano a cero, los datos de inversión en TV están muy bien repartidos alrededor de la media. El boxplot no muestra grandes asimetrías.

Radio: También es prácticamente simétrica. Hay un equilibrio casi perfecto entre inversiones altas y bajas, leve asimetría positiva con sesgo a la derecha.

Newspaper: Es la variable más sesgada. Significa que la mayoría de los datos están concentrados en valores bajos, pero existen algunos valores muy altos outliers que desplazan la cola hacia la derecha ósea positivo pronunciado, el boxplot evidencia valores atípicos extremos altos, con asimetría positiva marcada con sesgo a la derecha fuerte.

Sales: La cola se extiende hacia la derecha, esto nos indica que hay una tendencia a tener más registros de ventas bajos/medios, con algunos casos de ventas altas "estirando" el promedio Positivo ósea pronunciado.

¿Se identifican datos atípicos u observaciones que se alejan significativamente de la masa de los datos?:

Sí, en newspaper se muestra claramente valores atípicos altos estos puntos por encima del bigote en el boxplot, en cambio en TV, radio y sales no se observan outliers tan marcados.

Explique cómo podrían influir estas observaciones en la trayectoria de una línea de regresión:

Los datos atípicos pueden:

- Desviar la pendiente de la recta.
- Aumentar el error del modelo.
- Hacer que la línea se incline más hacia el valor extremo.
- Reducir la precisión de predicción.

Y pues en este caso los outliers de Newspaper podrían hacer que la regresión sobreestime o subestime la relación entre inversión en periódico y ventas.

3. Exploración de la Nube de Puntos:

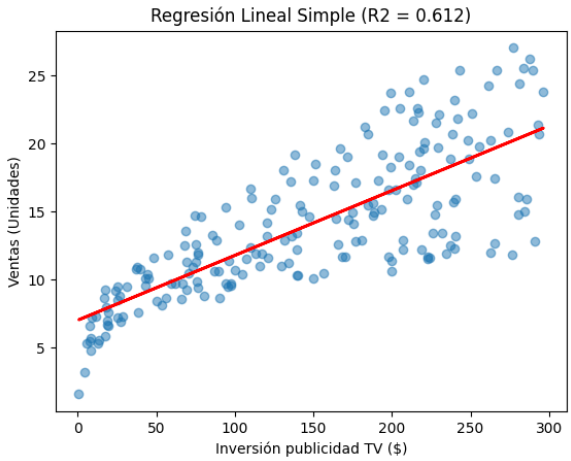

Ilustración 3 / Dispersograna referente a las ventas VS la inversión en TV

TV vs. Sales: Esto nos presenta una relación lineal simple y fuerte. La nube de puntos es estrecha y ascendente, siguiendo claramente la línea de regresión con un R^2 = 0.612. Es el predictor más fiable.

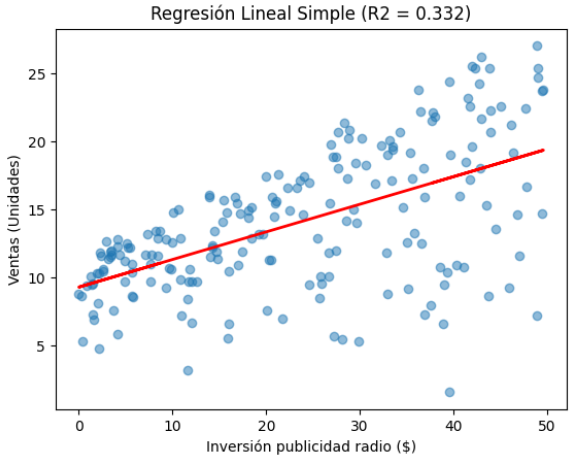

Ilustración 4 /Dispersograna referente a las ventas VS la inversión en radio

Radio vs. Sales: Esta sugiere una relación lineal moderada. Aunque hay una tendencia ascendente, los puntos están más dispersos R^2= 0.332, lo que indica una mayor variabilidad en los resultados de ventas por cada dólar invertido.

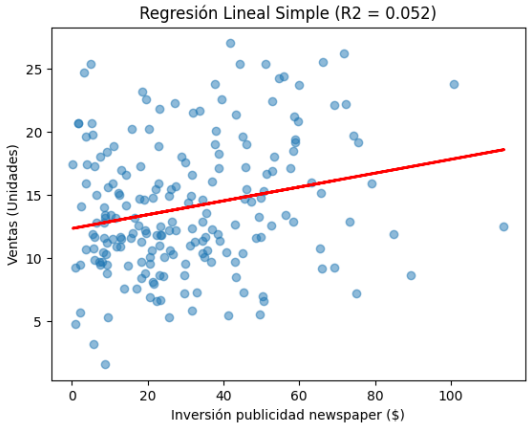

Ilustración 5 / Dispersograna referente a las ventas VS la inversión en newspaper

Newspaper vs. Sales: Nos muestra una relación lineal clara R^2= 0.052. La nube es muy dispersa y se identifican datos influyentes (atípicos) en el extremo derecho (inversiones > 100) que no generan un aumento proporcional en ventas.

4. Evaluación de Asociación:

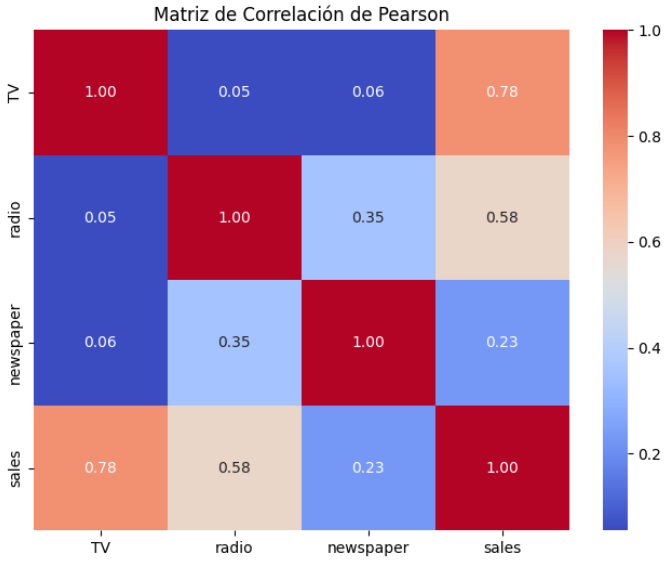

Ilustración 6 /Matriz de correlación de Pearson

En el análisis de correlación de Pearson revelo una relación lineal positiva fuerte entre la inversión en TV y las ventas (r = 0.78), una relación moderada para la inversión en radio con (r = 0.58) y una relación débil para Newspaper (r = 0.23), esto sugiriendo que la publicidad por TV es el predictor más fuerte respecto del incremento en las ventas.

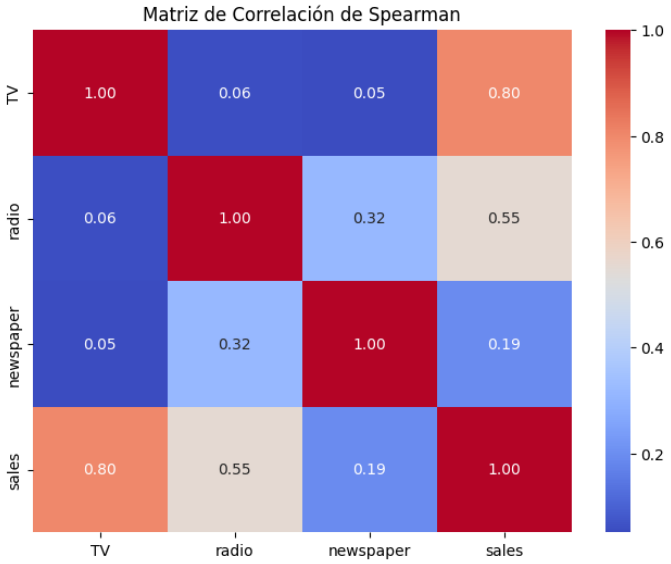

Ilustración 7 / Matriz de correlación de Spearman

Respecto al análisis de correlación de Spearman nos confirma una relación regularmente positiva fuerte entre la inversión en TV y las ventas (ρ = 0.80), una relación

moderada para Radio con (ρ = 0.55) y una relación muy débil para Newspaper (ρ = 0.19), esto validando que el orden jerárquico de la inversión publicitaria en TV es el que mejor que se alinea con el crecimiento respecto a las ventas.

5. Interpretación de Resultados: (Matriz de correlación de Pearson y Spearman):

¿Qué significa un coeficiente cercano a 1 o −1 en el contexto de la inversión publicitaria y el retorno en ventas?

En el contexto de marketing y ventas, estos valores indican la fuerza y dirección de la dependencia entre la inversión y el retorno

- **Cercano a 1 (Correlación positiva fuerte):** Esto indica que existe una relación directa y altamente predecible. Estadísticamente, significa que los incrementos en la inversión publicitaria por ejemplo en TV donde r = 0.78 están asociados de manera consistente con incrementos en las ventas.
- **Cercano a -1 (Correlación negativa fuerte):** Esto indicaría una relación inversa, donde a mayor inversión, las ventas disminuyen sistemáticamente, y según lo analizado en este conjunto de datos no se observa este hecho.

¿Cómo se interpreta un valor de correlación cercano a 0? Compare ambos coeficientes (Pearson y Spearman).

Un valor cercano a 0 como lo es el de Newspaper con r = 0.23 y ρ = 0.19 indica una ausencia de relación lineal, esto significa que la inversión en ese medio no explica las variaciones en las ventas, los cambios en una variable no permiten predecir la otra, comportándose de manera independiente.

Pearson vs. Spearman

Pearson (r): Mide la fuerza de la relación lineal (línea recta), en los datos obtenidos la TV tiene la asociación lineal más fuerte (r = 0.78).

Spearman (ρ): Mide la relación lineal (basada en rangos o el orden de los datos) y es menos sensible a valores atípicos, como para la TV este valor es mayor (ρ = 0.80), lo que sugiere una tendencia ascendente muy sólida.

¿Sugieren estos resultados que las relaciones son estrictamente lineales? Justifique su respuesta basándose en la forma de la nube de puntos observada.

No, aunque hay tendencias claras de que los resultados sugieren que las relaciones no son estrictamente lineales por dos razones principales observadas en las nubes de puntos:

Diferencia de Coeficientes: En el caso de la TV, el hecho de que Spearman (ρ = 0.80) sea superior a Pearson (r = 0.78) indica que la relación siempre crece, pero no necesariamente a un ritmo constante o perfectamente recto.

Forma de la Nube: Las gráficas muestran heterocedasticidad que es la dispersión de los puntos aumenta conforme sube la inversión, especialmente en TV y la radio y presencia de datos atípicos en Newspaper. Estos fenómenos como que ensucian la trayectoria de la línea recta ideal, indicando que un modelo lineal simple es una buena aproximación, pero no una descripción perfecta de la realidad.

FASE 2: Regresión Lineal y Diagnóstico

1. Modelamiento Múltiple:

Basado en la salida del modelo de regresión lineal múltiple, los coeficientes estimados para la variable respuesta Sales son:

```
--- Coeficientes del Modelo ---
Intercepto (beta_0): 2.9389
Coeficiente TV (beta_1): 0.0458
Coeficiente Radio (beta_2): 0.1885
Coeficiente newspaper (beta_3): -0.0010

--- Bondad de Ajuste ---
R-cuadrado (R2): 0.8972
```

Ilustración 8 / Coeficientes estimados

Ecuación de la recta estimada:

$$sales = 2.9389 + 0.0458(TV) + 0.1885(radio) - 0.0010(newspaper)$$

El $R^2 = 0.8972$, esto indica que el modelo logra explicar aproximadamente el 89.72% de la variabilidad de las ventas utilizando las tres fuentes de inversión publicitaria.

2. Interpretación de Parámetros:

Intercepto $\widehat{\beta_0}$ = 2.9389 Representa el nivel esperado de ventas aproximadamente 2,939 unidades cuando la inversión en TV, Radio y Periódico es cero.

$\widehat{\beta_1}$ (TV): Por cada dólar adicional invertido en publicidad por TV, se espera que las ventas aumenten en promedio 0.0458 unidades, manteniendo constantes las inversiones en Radio y Periódico.

$\widehat{\beta_2}$ (Radio): Por cada dólar adicional en Radio, las ventas aumentan en promedio 0.1885 unidades, manteniendo constantes las demás variables. Es el canal con mayor impacto por unidad invertida.

$\widehat{\boldsymbol{\beta}_3}$ **(Newspaper):** Este coeficiente es casi nulo con -0.0010), esto indica que el incremento en publicidad por periódico no tiene un efecto real en las ventas; de hecho, muestra una relación levemente negativa, sugiriendo que es una inversión ineficiente en este modelo.

3. Análisis de Bondad de Ajuste:

Coeficiente de Determinación $R^2 = \$0.8972\$$

Interpretación: El modelo nos explica el 89.72% de la variabilidad total de las ventas lo cual indica un ajuste global muy alto y robusto.

Análisis Comparativo: En la Fase 1, el modelo simple (solo TV) tenía un $R^2 = 0.612$. Al incluir Radio y Newspaper, el ajuste mejoró significativamente, pasando del 61.2% al 89.7%. Esta mejora se debe principalmente a la inclusión de la variable Radio, que tiene una fuerte influencia positiva, mientras que Newspaper aporta muy poco al poder explicativo del modelo final.

4. Estimación Matricial:

$$\boldsymbol{X} = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}; \quad \boldsymbol{Y} = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$

- Calcule la matriz transpuesta X'.

$$\boldsymbol{X^T} = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} * \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}$$

- Calcule el producto $X'X$ y su respectiva matriz inversa $(X'X)^{-1}$.

$$\boldsymbol{X'X} = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} * \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix} = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}$$

Determinante de A:

$$\boldsymbol{Determinante\ de\ A} = 5 * 55 - 15 * 15$$

$$\boldsymbol{Determinante\ de\ A} = 275 - 225$$

$$\boldsymbol{Determinante\ de\ A} = 50$$

$$\boldsymbol{(X'X)^{-1}} = \frac{1}{50} * \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix} = \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix}$$

- Calcule el producto $X'Y$.

$$\boldsymbol{X'Y} = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} * \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix} = \begin{pmatrix} 28 \\ 101 \end{pmatrix}$$

- Obtenga el vector de parámetros $\hat{\beta}$ y escriba la ecuación de la recta estimada $\hat{y} = \widehat{\beta_0} + \widehat{\beta_1}x$.

$$\hat{\beta} = (X'X)^{-1} * X'Y$$

$$\hat{\beta} = \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix} * \begin{pmatrix} 28 \\ 101 \end{pmatrix}$$

$$\widehat{\beta_0} = (1.1 * 28) + (-0.3 * 101) = 0.5$$

$$\widehat{\beta_1} = (-0.3 * 28) + (0.1 * 101) = 1.7$$

$$\boldsymbol{\hat{y} = 0.5 + 1.7\,x}$$

FASE 3: Arboles de Decisión y Comparación de Modelos

1. Entrenamiento del Modelo:

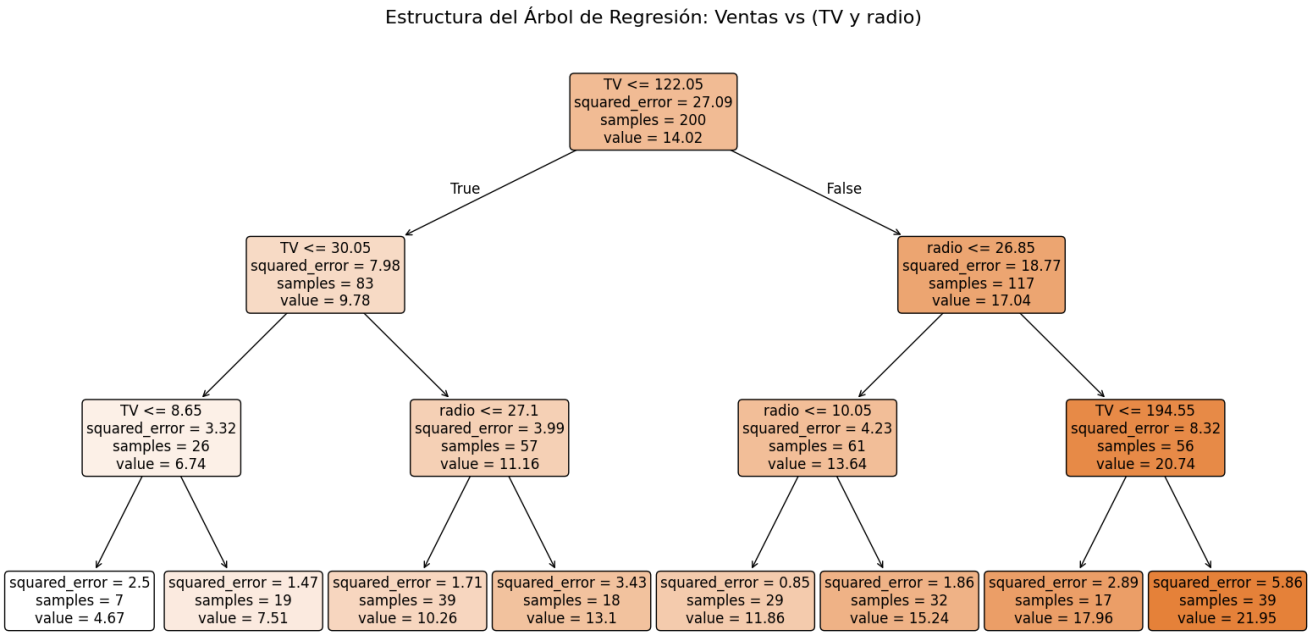

Ilustración 9 / Estructura del Árbol de Regresión: Ventas vs (TV y radio)

El árbol de regresión fue creado usando TV y Radio para predecir Sales, las particiones en los nodos se realizan utilizando el criterio de reducción del error cuadrático medio (MSE), seleccionando en cada división el punto de corte que minimiza la varianza de las ventas dentro de cada grupo, la primera división se hace sobre la variable TV, indicando que es la variable más influyente en la predicción. Posteriormente, se realizan divisiones adicionales sobre TV y Radio para formar grupos más homogéneos y mejorar la precisión del modelo.

2. Cálculo Manual de Incertidumbre (Clasificación):

Mercado	Inversión TV	Ventas (Clase)
1	Alta	Altas
2	Alta	Altas
3	Baja	Bajas
4	Baja	Altas

Tabla 2 / Datos de 4 mercados

- Calcule la Entropía del Nodo Padre: $H(S) = -\sum pi \ \log_2(pi)$.

2 Calculo manual de incertidumbre (clasificación).

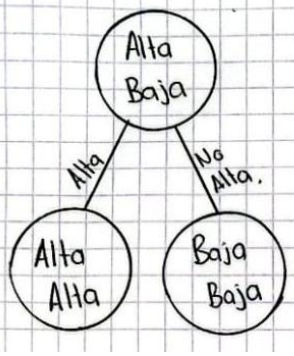

$$H(S) = \left(\frac{3}{4} \log_2 \frac{3}{4} + \frac{1}{4} \log_2 \frac{1}{4}\right)$$

$$H(S) = 0.811 \text{ bits}$$

- Calcule el índice de Gini para el nodo padre: $Gini = 1 - \sum p_i^2$.

$$\text{Giní} = 1 - \left(\frac{3}{4}^2 + \frac{1}{4}^2\right)$$

$$\text{Giní} = 0.375$$

- Determine la Ganancia de Información tras realizar una partición por la variable Inversión TV.

- Grupo Tv alta = Mercado 1 y 2 ambos altos Entropia = 0
- Grupo Tv Bajo = Mercado 3 y 4 una baja y una alta entropia = 1
- Entropia Ponderada = Gain = H(s) Padre $- \sum_{i=\text{hijos}}$

$$= 0.811 \text{ bits} - \left(\cancel{\frac{2}{4}^2 \cdot 0}^{\,0} + \frac{2}{4} \cdot 1\right)$$

$$= 0.811 \text{ bits} - 0.5 \text{ bit}$$

$$= \boxed{0.311 \text{ bits}}$$

3. Importancia de Predictores:

En el Árbol de Decisión: La variable con mayor peso es TV. Estadísticamente, esto se evidencia porque es la variable seleccionada para realizar la partición primaria en el nodo raíz TV $\leq$ 122.05, lo que significa que es el predictor que logra la mayor reducción inicial en la varianza (o impureza) de las ventas.

En la Regresión Múltiple: Si bien TV es significativa $\widehat{\beta_1}$= 0.0458, la variable Radio presenta el coeficiente de pendiente más alto $\widehat{\beta_2}$ = 0.1885. Esto indica que, bajo un modelo lineal, la Radio genera un mayor cambio esperado en la media de ventas por cada unidad incremental de inversión.

Comparación: Existe una divergencia técnica, el árbol prioriza a TV por su capacidad para explicar la estructura global de los datos y las interacciones no lineales, en cambio la regresión resalta la eficiencia marginal de la Radio, sugiriendo que aunque la TV define la escala de las ventas, la Radio tiene un impacto proporcional más fuerte en el modelo aditivo.

4. Diagnóstico Comparativo:

La regresión lineal es preferible cuando se busca interpretabilidad global, ya que permite cuantificar el impacto marginal exacto de cada dólar invertido mediante coeficientes fijos. Por el contrario, el árbol de decisión es superior en precisión cuando existen interacciones no lineales entre medios, ya que segmenta los datos sin asumir una forma funcional rígida. Mientras la regresión es más robusta para la inferencia, el árbol captura mejor patrones complejos y es menos sensible a valores atípicos.

Conclusiones:

Tras evaluar ambos modelos para el conjunto de datos, se concluye que la regresión lineal múltiple es el modelo más robusto y adecuado para este caso particular. Aunque el árbol de decisión logra identificar a la televisión como el nodo crítico de partición, la regresión ofrece una mayor interpretabilidad de los coeficientes, permitiendo cuantificar que por cada unidad adicional invertida, la Radio genera el mayor retorno marginal. Dado que la relación entre la inversión publicitaria y las ventas presenta una tendencia marcadamente lineal y continua, el modelo de regresión captura mejor la sensibilidad del mercado sin los saltos discretos o el riesgo de sobreajuste propios de los árboles.

En definitiva, mientras el árbol es útil para segmentar mercados de forma rápida, la regresión lineal proporciona la precisión matemática necesaria para la optimización presupuestaria y la inferencia estadística confiable que requiere el negocio.